MINERÍA DE DATOS Y MODELIZACIÓN PREDICTIVA

'Análisis y predicción de series temporales'

Pedro Pablo Vicente González, 48751969 L

Entrega: 29/05/2025

1- Introducción, presentación de la serie y objetivo de estudio.

La serie con la que vamos a trabajar es el índice de precios al consumo (IPC) del turismo y hostelería de la Región de Murcia. Se trata de un índice de elaboración mensual, publicado por el INE, en el cual se recoge la evolución de los precios de una cesta de bienes y servicios significativa para el sector "turismo y hostelería".

El objetivo de este trabajo es el estudio de esta serie y la predicción de esta en base a su histórico. Encontraremos características propias de una serie temporal que, agitada por las distintas coyunturas económicas, nos ofrecerá la estacionalidad propia del sector y cambios de tendencia.

El enlace a la descarga del set de datos es https://www.ine.es/consul/download.do?idPeticion=1747840915784&idiomaPeticion=es&tipofichero=4&descargarformato=Ir ; tanto el set original como el modificado se encuentran adjuntos a este archivo.

	A	B	C
4	Serie,IPC261391		
5	Periodicidad,Mensual		
6	Unidad,Ãndice		
7	DATOS		
8	PERIODO,VALOR,TIPO DATO,NOTA		
9	2025M04,123,566,Definitivo,		
10	2025M03,121,457,Definitivo,		
11	2025M02,120,717,Definitivo,		
12	2025M01,119,488,Definitivo,		
13	2024M12,121,576,Definitivo,		

Archivo original "series1357457496c"

	A	B	C
1	PERIODO,VALOR,TIPO DATO,NOTA		
2	2025M04,123,566,Definitivo,		
3	2025M03,121,457,Definitivo,		
4	2025M02,120,717,Definitivo,		
5	2025M01,119,488,Definitivo,		
6	2024M12,121,576,Definitivo,		
7	2024M11,119,659,Definitivo,		

Archivo "murciaTurismo"

La serie abarca desde enero de 2002 hasta marzo de 2025 y utiliza como índice 100= junio de 2020. Se trata de un set de datos con 275 muestras y 4 variables: 'PERIODO', 'TIPO DATO', 'NOTA' y 'VALOR'. La forma de proceder para asegurar la legibilidad de los datos ha sido dejando 'PERIODO' y 'VALOR', por ser los datos relevantes, eliminando aquellas filas irrelevantes para su procesamiento en Python (el archivo resultante es "murciaTurismo". 'PERIODO' ha sido tratada como índice y renombrada a

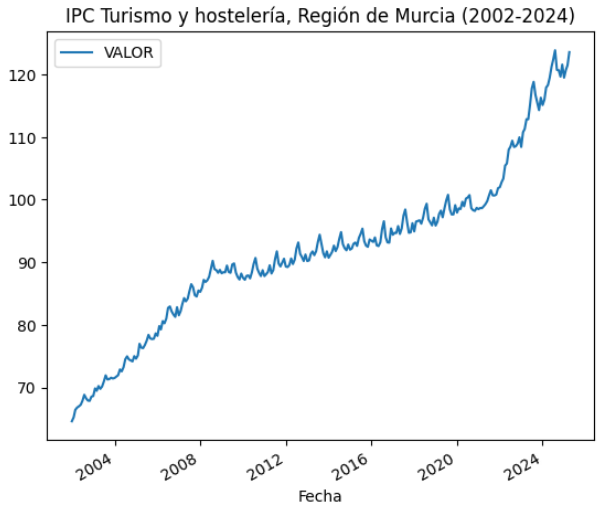
'Fecha'; y 'VALOR' ha sido renombrada a 'IPC'. Finalmente, los datos han sido reordenados para que aparezcan en orden temporal. Todo el código utilizado queda adjunto mediante el cuaderno Jupyter Notebook (.ipynb) explicativo.

Fecha	IPC
2002-01-01	64.595
2002-02-01	65.226
2002-03-01	66.420
2002-04-01	66.780
2002-05-01	66.977
...	...
2024-07-01	122.430
2024-08-01	123.863
2024-09-01	120.732
2024-10-01	120.682
2024-11-01	119.659

Datos con los que trabajaremos.

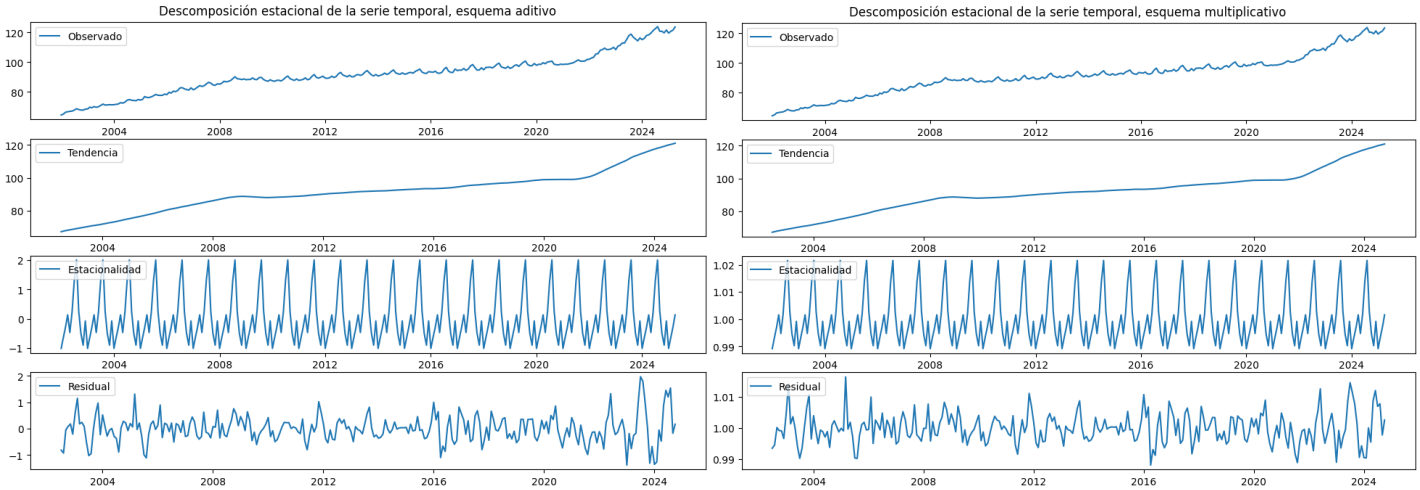
2- Representación gráfica y descomposición de la serie.

La representación de la serie revela la presencia de tendencia y de estacionalidad a lo largo de esta. A primera vista podemos observar hasta dos cambios de tendencia, uno alrededor de 2009 y otro en 2020, ambos causados por crisis económicas: la recesión económica de 2008 y la crisis global del COVID 19.



Nos encontramos ante una serie con varias tendencias, todas crecientes, y picos de crecimiento en torno a los meses de verano (julio y agosto), lo que denota existencia de estacionalidad. La presencia de tendencia y estacionalidad, sumada a la posible presencia de heterocedasticidad (no tan clara), nos hace tener que probar tanto a realizar nuestro modelo mediante un esquema aditivo como con uno multiplicativo. Utilizando *statsmodels.tsa.seasonal_decompose* obtengo rápidamente ambos modelos. A fin de trabajar más rápidamente, he asignado a cada modelo una variable correspondiente a la función *plt_descomposicion_serie,* con la que, además de mostrar gráficamente la descomposición del modelo, guardo los resultados de aplicar *seasonal_decompose* con ambos modelos. Así, *modelo_a* es la variable que corresponde al modelo aditivo y *modelo_m* al multiplicativo.

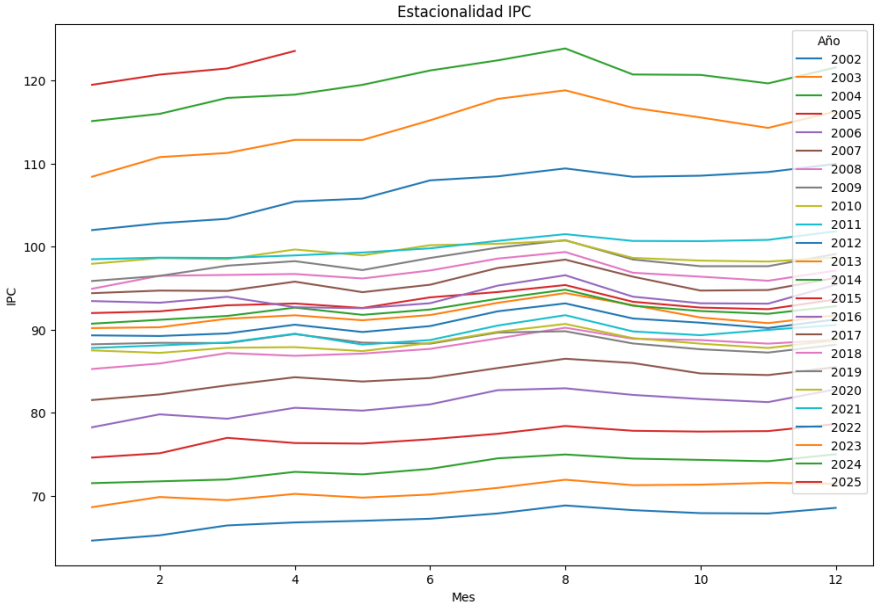
Los resultados son:



En estos gráficos queda recogida la serie y su descomposición en tres de sus componentes: tendencia, estacionalidad y residual. La descomposición es interesante porque nos permite ver el efecto aislado de cada componente, así es más sencillo reconocer la existencia de tendencia y estacionalidad. Vemos que la componente residual parece ser estacionaria, tiene forma de ruido blanco, lo que significa que la descomposición ha capturado bien el resto de componentes.

Los resultados obtenidos para ambos esquemas son similares, pero no idénticos. Si, por ejemplo, nos fijamos en la escala de la componente estacional, veremos que es distinta dependiendo del tipo de esquema por la forma en que los coeficientes estacionales son calculados (Esquema aditivo: X_i-S_i | Esquema multiplicativo: X_i/S_i). En ambos esquemas podemos confirmar las características que veníamos comentando, podemos fácilmente identificar hasta tres procesos de tendencia y la existencia de estacionalidad a lo largo de la serie.

También podemos estudiar estas relaciones visualizando los valores observados por año.

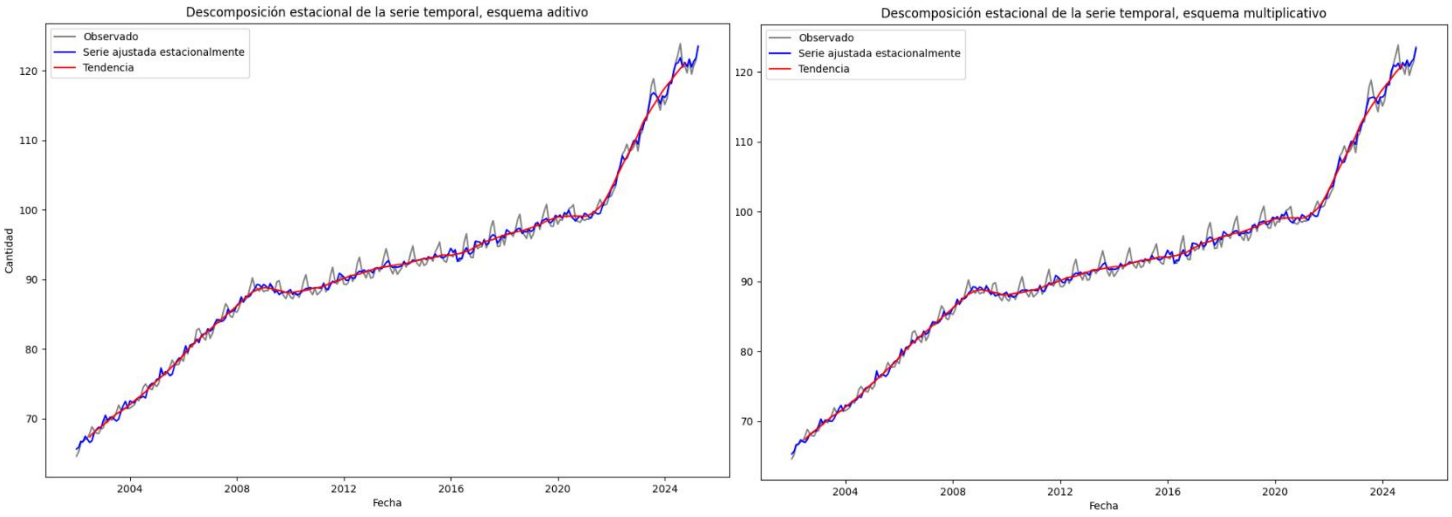


Esta visualización nos permite hacer dos observaciones:

La primera es que, aun pudiendo distinguir la existencia de estacionalidad, esta se ve suavizada por el efecto del resto de componentes, y por ello es importante aislar este componente.

La segunda observación es con respecto a la tendencia. Ya que nuestra serie es creciente, podemos claramente distinguir los tres ritmos de crecimiento (las tres principales tendencias) que toma la serie, un crecimiento más rápido del IPC da a mayor separación entre las líneas de valor del IPC. De esa forma, notamos tres periodos: 2002-2008, 2008-2021 (crecimiento más lento, mayor aglomeración de los valores), 2021-Actualidad.

Otra forma de visualizar las componentes de cada modelo es superponiendo estas sobre los valores observados:



3- Preparación de predicciones.

Antes de utilizar ningún modelo para predecir datos a futuro, debemos reservar datos a fin de poder establecer una comparación entre lo que nuestro modelo es capaz de hacer y la realidad observada. Por ello, he creado una nueva serie en la que se obvian los últimos 12 datos (meses), con la finalidad de establecer este año como punto de comparación.

4- Modelo de suavizado exponencial más adecuado.

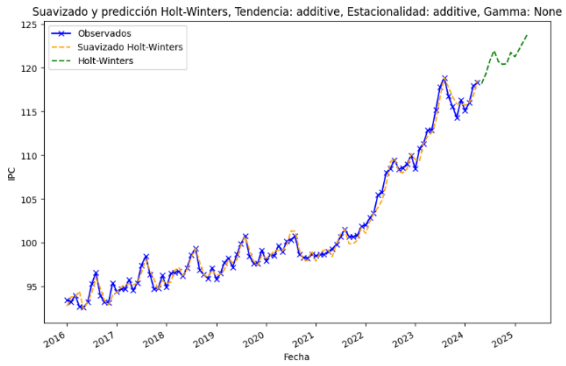
El modelo de suavizado exponencial más indicado para series que presentan estacionalidad y tendencia es el modelo de alisado Holt-Winters. Este modelo se diferencia del alisado simple y doble en que hace uso de un parámetro gamma para modelizar la estacionalidad. También utiliza los parámetros alfa (como el de alisado simple) y beta (como el de alisado doble) para, respectivamente, modelizar la ponderación que se da a datos recientes y la sensibilidad que se da a cambios de tendencia.

A la hora de aplicar nuestro modelo de suavizado Holt-Winters con predicciones vamos a tener en cuenta tanto este parámetro gamma como el esquema de modelización para la tendencia y la estacionalidad.

-En el caso del parámetro gamma, un gamma cercano a 0 implicará una componente estacional con poco movimiento: un gamma 0 significará una estacionalidad constante para nuestro modelo, mientras que un gamma de 1 modelizará mejor los cambios en esta. Como hemos visto, nuestra estacionalidad es constante, se trata de un patrón estacional anual que se repite de igual forma entre meses, por ello utilizaremos un parámetro *Gamma = None*, el cual sabemos que será cercano a Gamma = 0. La razón para utilizar *None* como input es que, el código, se encargará de optimizar el parámetro por nosotros, de la misma forma en que optimiza el alfa y beta del modelo.

-Por otra parte, tendremos que elegir si modelizar nuestro suavizado mediante esquemas aditivos, multiplicativos o mixtos, a continuación, probamos crear los cuatro posibles modelos:

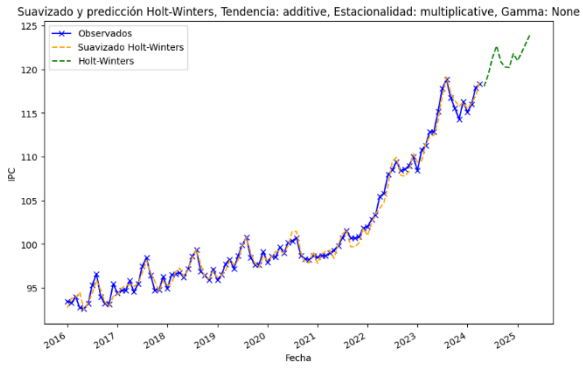
Modelo aditivo (1)



ExponentialSmoothing Model Results			
Dep. Variable:	IPC	No. Observations:	268
Model:	ExponentialSmoothing	SSE	78.661
Optimized:	True	AIC	-296.524
Trend:	Additive	BIC	-239.068
Seasonal:	Additive	AICC	-293.777
Seasonal Periods:	12	Date:	Wed, 28 May 2025
Box-Cox:	False	Time:	17:13:37
Box-Cox Coeff.:	None		

	coeff	code	optimized
smoothing_level	0.8153599	alpha	True
smoothing_trend	0.0567067	beta	True
smoothing_seasonal	8.7222e-18	gamma	True

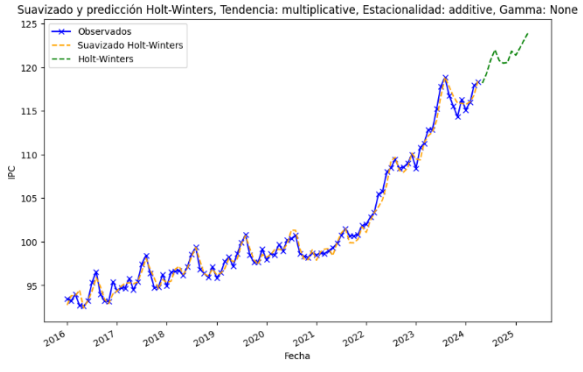
Modelo mixto (2)



ExponentialSmoothing Model Results			
Dep. Variable:	IPC	No. Observations:	268
Model:	ExponentialSmoothing	SSE	78.721
Optimized:	True	AIC	-296.320
Trend:	Multiplicative	BIC	-238.864
Seasonal:	Additive	AICC	-293.573
Seasonal Periods:	12	Date:	Wed, 28 May 2025
Box-Cox:	False	Time:	17:13:28
Box-Cox Coeff.:	None		

	coeff	code	optimized
smoothing_level	0.8164669	alpha	True
smoothing_trend	0.0558713	beta	True
smoothing_seasonal	6.9774e-14	gamma	True

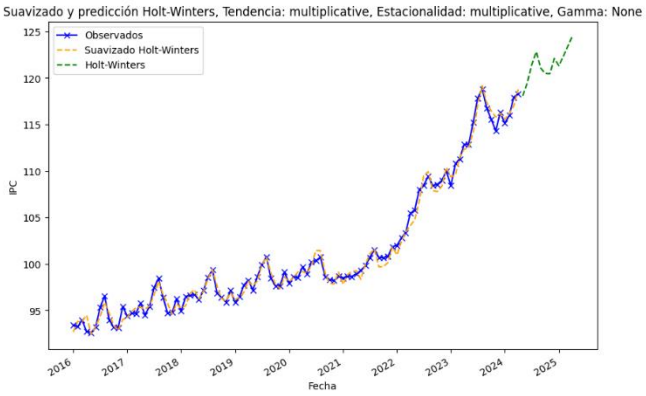
Modelo mixto (3)



ExponentialSmoothing Model Results			
Dep. Variable:	IPC	No. Observations:	268
Model:	ExponentialSmoothing	SSE	69.937
Optimized:	True	AIC	-328.029
Trend:	Additive	BIC	-270.573
Seasonal:	Multiplicative	AICC	-325.282
Seasonal Periods:	12	Date:	Wed, 28 May 2025
Box-Cox:	False	Time:	17:13:24
Box-Cox Coeff.:	None		

	coeff	code	optimized
smoothing_level	0.7754692	alpha	True
smoothing_trend	0.0688237	beta	True
smoothing_seasonal	2.9514e-16	gamma	True

Modelo multiplicativo (4)



ExponentialSmoothing Model Results

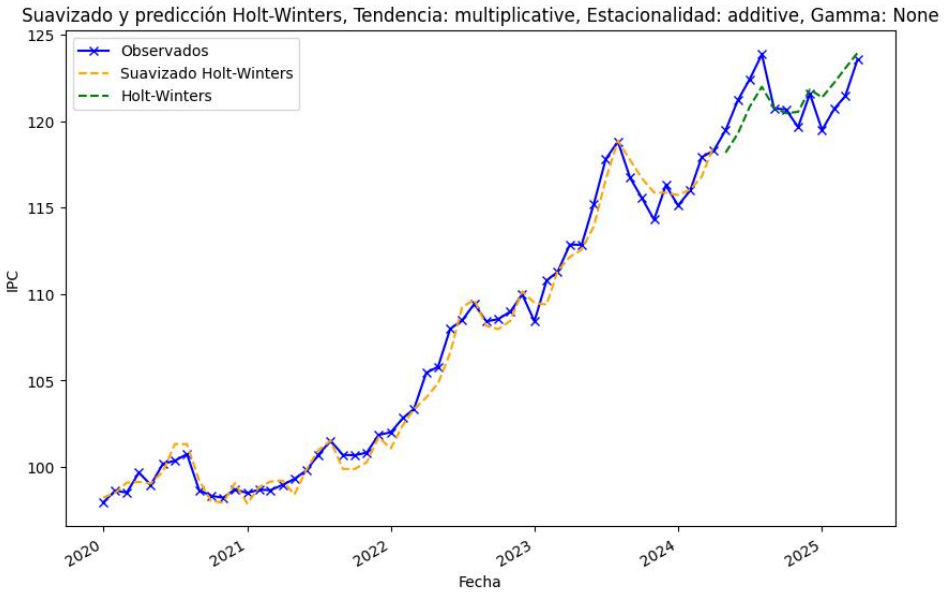
Dep. Variable:	IPC	No. Observations:	268
Model:	ExponentialSmoothing	SSE	70.176
Optimized:	True	AIC	-327.114
Trend:	Multiplicative	BIC	-269.658
Seasonal:	Multiplicative	AICC	-324.367
Seasonal Periods:	12	Date:	Wed, 28 May 2025
Box-Cox:	False	Time:	17:14:06
Box-Cox Coeff.:	None		

	coeff	code	optimized
smoothing_level	0.7792457	alpha	True
smoothing_trend	0.0666891	beta	True
smoothing_seasonal	5.5407e-15	gamma	True

Podemos observar en los distintos resúmenes que *Gamma (smoothing_seasonal)* es un número cercano, pero no igual, a 0. Basándonos en el criterio de selección bayesiano y de Akaike, el modelo que mejor se ajusta es el *Modelo mixto (3)*: de tendencia modelizada de forma multiplicativa y la estacionalidad modelizada de forma aditiva, por presentar los valores más bajos para ambos criterios.

Una aclaración sobre el código utilizado es que he utilizado la serie sin los últimos 12 valores para entrenar los modelos y tener una predicción sobre estos mismos 12 valores. La serie con la que estamos trabajando es algo grande por lo que he ajustado el código de los gráficos para mostrar solo aquellos valores a partir de 2016, sin que ello signifique que se haya dejado de trabajar con valores anteriores.

Representación a partir de 2020 del modelo ganador, comparando los datos observados y los estimados para el último año:



La expresión para el modelo se construye a partir de los coeficientes obtenidos en el resumen (*modelo_holt_winters.summary()*):

$$L_t = \alpha \frac{Xt}{St-s} + (1 - \alpha)\,(L_{t-1} + b_{t-1})$$

$$b_t = \beta\,(L_t - L_{t-1}) + (1 - \beta)\,b_{t-1}$$

$$S_t = \gamma \frac{Xt}{Lt} + (1 - \gamma)\,S_{t-s}$$

$$\hat{X}_{t+1} = (L_t - b_t)\,S_{t+1-s} \quad \text{(estimaciones)}$$

ExponentialSmoothing Model Results

Dep. Variable:	IPC	No. Observations:	268
Model:	ExponentialSmoothing	SSE	69.937
Optimized:	True	AIC	-328.029
Trend:	Additive	BIC	-270.573
Seasonal:	Multiplicative	AICC	-325.282
Seasonal Periods:	12	Date:	Wed, 28 May 2025
Box-Cox:	False	Time:	18:19:38
Box-Cox Coeff.:	None		

	coeff	code	optimized
smoothing_level	0.7754692	alpha	True
smoothing_trend	0.0688237	beta	True
smoothing_seasonal	2.9514e-16	gamma	True
initial_level	60.624543	l.0	True
initial_trend	0.2740579	b.0	True
initial_seasons.0	1.0615124	s.0	True
initial_seasons.1	1.0662057	s.1	True
initial_seasons.2	1.0704925	s.2	True
initial_seasons.3	1.0755192	s.3	True
initial_seasons.4	1.0679271	s.4	True
initial_seasons.5	1.0760878	s.5	True
initial_seasons.6	1.0890049	s.6	True
initial_seasons.7	1.0971230	s.7	True
initial_seasons.8	1.0767310	s.8	True
initial_seasons.9	1.0674405	s.9	True
initial_seasons.10	1.0627148	s.10	True
initial_seasons.11	1.0727532	s.11	True

Con:

α = smoothing_level

β = smoothing_trend

γ = smoothing_seasonal

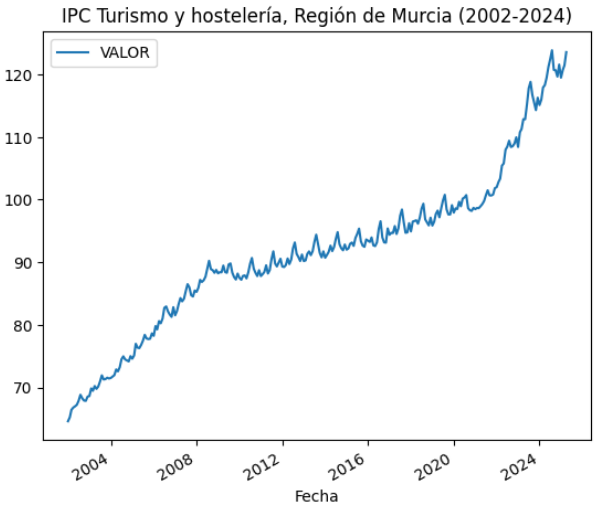
L_0 = initial_level

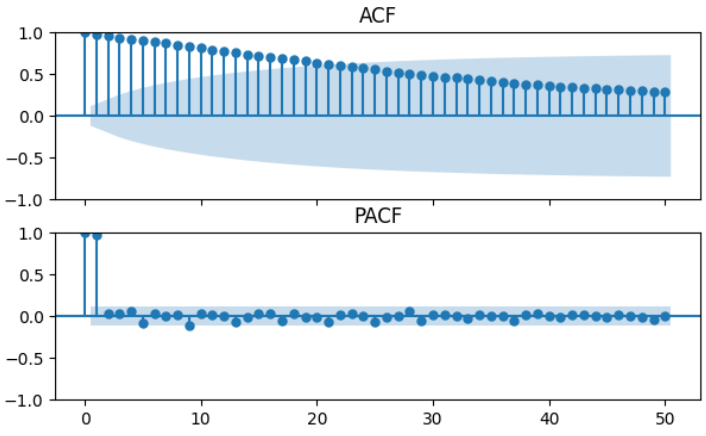
b_0 = initial_trend

S_i = initial_seasons.i, con S_0= 1.061512 hasta S_{11}= 1.0727532.

5- Representación de la serie y las funciones de autocorrelación y autocorrelación parcial.

Serie original



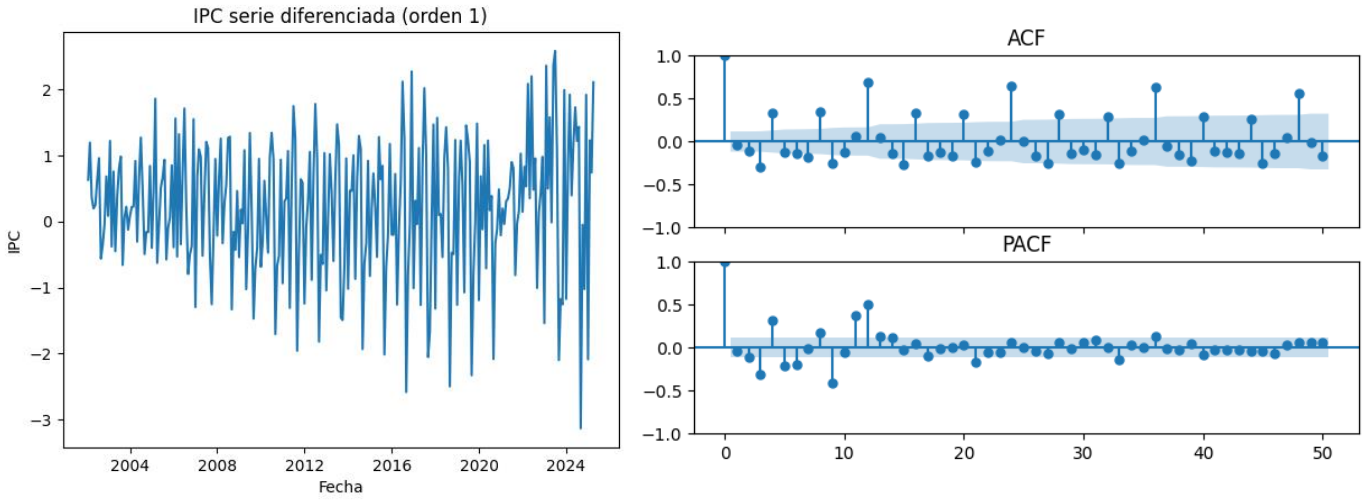


Como podemos observar en los correlogramas, nuestra serie original muestra indicios de no estacionariedad: la función de autocorrelación cae lentamente y de forma lineal, alrededor del retardo 20 los retardos dejan de ser significativos; y la función de autocorrelación parcial cae rápidamente tras el primer retardo. Esto sucede a raíz de la presencia de tendencia y estacionalidad.

La forma en la que vamos a estacionarizar nuestra serie va a ser a través de la diferenciación de la serie, en primer lugar, mediante diferencias de primer orden (de esa forma conseguimos corregir la tendencia):

Serie diferenciada de orden 1

df_diff = df['IPC'].diff(1).dropna()



Como podemos ver, nuestra serie ya no presenta tendencia, sin embargo, seguimos notando la presencia de la estacionalidad, tanto en la representación de la serie como en sus correlogramas (aquí, podemos notar esos picos de autocorrelación, sobre todo cada 12 retardos). Podemos comprobar la existencia de estacionariedad a través del *contraste de raíz unitaria de Dickey-Fuller*, cuya hipótesis nula es que la serie no es estacionaria (tiene una raíz unitaria). Los resultados de su cálculo son:

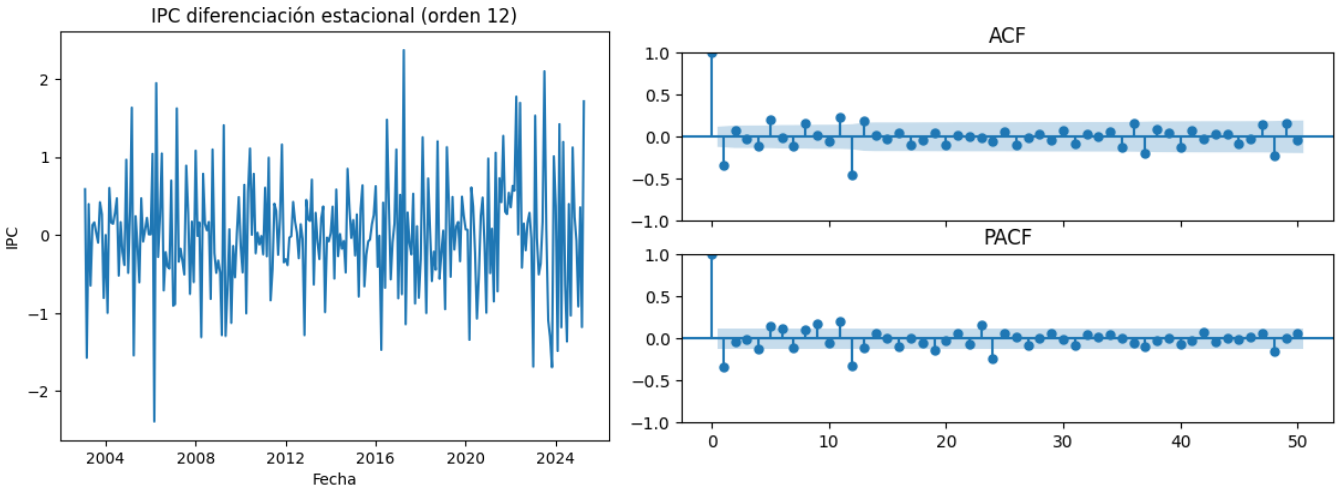
```
Estadístico ADF: -1.6539638070094707
Valor p: 0.4549740103517427
Retardos utilizados: 13
Número de observaciones: 265
Valores críticos: {'1%': -3.4552699038400827, '5%': -2.8725092359464526, '10%': -2.5726152830188678}
Información adicional: 492.48454325987973
```

El resultado es que la serie con diferencias de primer orden no presenta estacionariedad, $p = 0.46 > 0.05$, por lo que rechazamos H_0.

Para eliminar la estacionalidad de la serie vamos a llevar a cabo una diferenciación de orden 12 para nuestra serie diferenciada de orden 1:

Serie doblemente diferenciada de orden 12

df_seasonal_diff = df_diff.diff(12).dropna()



Al llevar a cabo la doble diferenciación, eliminamos el efecto de la estacionalidad. Podemos observar en los correlogramas como los retardos caen rápidamente tras el primer retardo, aún conservando la significativadad para los retardos múltiplos de su orden (retardos 12 y 24). Volvemos a calcular el contraste de Dickey-Fuller para confirmar que nuestra serie ya no es estacionaria:

```
Estadístico ADF: -4.7535003885590035
Valor p: 6.669138214252253e-05
Retardos utilizados: 12
Número de observaciones: 254
Valores críticos: {'1%': -3.456360306409983, '5%': -2.8729872043802356, '10%': -2.572870232500465}
Información adicional: 479.41199547868416
```

El resultado es que la serie con diferencias de orden 12 ya *presenta estacionariedad*, $p \approx 0 < 0.05$, por lo que no rechazamos H_0.

Vamos a trabajar con esta serie mediante un ARIMA estacional. Gracias a las diferenciaciones ya sabemos algunos de los parámetros con los que vamos a probar:

d = 1 (por la diferenciación de primer orden), D = 1 (por la diferenciación estacional), s = 12 (estacionalidad anual, en meses).

Para establecer los parámetros p y q de la parte no estacional AR(p) y MA(q), nos fijamos en los retardos de las funciones PACF y ACF, respectivamente. La rápida caída en la significativadad de los retardos tras el primero, en ambas funciones, sugiere que p = 1 y q = 1. Para elegir P y Q nos fijamos en los retardos múltiplos de s, que sugieren que P = 2 (tal vez hasta 4) y Q = 1.

Este establecimiento de los parámetros del modelo es provisional, el modelo con el que comenzaremos a probar es:

(1) *ARIMA (1, 1, 1) (2, 1, 1)$_{12}$*

SARIMAX Results

Dep. Variable:			IPC	No. Observations:		280
Model:	SARIMAX(1, 1, 1)x(2, 1, 1, 12)			Log Likelihood		-240.373
Date:	Thu, 29 May 2025			AIC		492.746
Time:	12:27:58			BIC		514.270
Sample:	01-01-2002			HQIC		501.392
	- 04-01-2025					
Covariance Type:	opg					
	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-0.3851	0.302	-1.274	0.203	-0.978	0.207
ma.L1	0.1995	0.307	0.651	0.515	-0.401	0.800
ar.S.L12	-0.8878	0.177	-5.005	0.000	-1.235	-0.540
ar.S.L24	-0.4401	0.085	-5.171	0.000	-0.607	-0.273
ma.S.L12	0.3287	0.194	1.697	0.090	-0.051	0.708
sigma2	0.3470	0.025	14.088	0.000	0.299	0.395

Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):	13.96
Prob(Q):	0.99	Prob(JB):	0.00
Heteroskedasticity (H):	2.10	Skew:	0.23
Prob(H) (two-sided):	0.00	Kurtosis:	4.03

Los resultados del modelo no son buenos, varios de los coeficientes no son significativos, pero el contraste de hipótesis de Ljung-Box = 0, con $p < 0.05$. Siendo la hipótesis nula que los residuos del modelo no estén correlacionados en el tiempo, lo que significa es que nuestro modelo es válido. Probamos con otro modelo a fin de aplicar "principio de simplificación":

(2) *ARIMA (1, 1, 1) (1, 1, 1)$_{12}$*

SARIMAX Results

Dep. Variable:			IPC	No. Observations:		280
Model:	SARIMAX(1, 1, 1)x(1, 1, 1, 12)			Log Likelihood		-236.665
Date:	Thu, 29 May 2025			AIC		483.329
Time:	15:49:05			BIC		501.266
Sample:	01-01-2002			HQIC		490.534
	- 04-01-2025					
Covariance Type:	opg					
	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-0.3844	0.283	-1.356	0.175	-0.940	0.171
ma.L1	0.1738	0.287	0.606	0.544	-0.388	0.736
ar.S.L12	0.0305	0.098	0.310	0.756	-0.162	0.223
ma.S.L12	-0.6932	0.085	-8.157	0.000	-0.860	-0.527
sigma2	0.3353	0.026	12.697	0.000	0.284	0.387

Ljung-Box (L1) (Q):	0.00	Jarque-Bera (JB):	7.77
Prob(Q):	0.98	Prob(JB):	0.02
Heteroskedasticity (H):	1.83	Skew:	0.24
Prob(H) (two-sided):	0.00	Kurtosis:	3.68

En este segundo modelo obtenemos un AIC y BIC inferiores, pero seguimos teniendo mala significatividad de nuestros coeficientes. El estadístico Ljung-Box nos sigue indicando que el modelo está bien ajustado con respecto de las autocorrelaciones de residuos.

(3) *ARIMA (3, 1, 2) (3, 1, 1)$_{12}$*

SARIMAX Results

Dep. Variable:			IPC	No. Observations:		280
Model:	SARIMAX(3, 1, 2)x(3, 1, [1], 12)			Log Likelihood		-230.929
Date:	Thu, 29 May 2025			AIC		481.858
Time:	16:01:00			BIC		517.731
Sample:	01-01-2002			HQIC		496.268
	- 04-01-2025					
Covariance Type:			opg			

	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-1.1632	0.059	-19.679	0.000	-1.279	-1.047
ar.L2	-0.9849	0.082	-12.027	0.000	-1.145	-0.824
ar.L3	-0.1152	0.067	-1.726	0.084	-0.246	0.016
ma.L1	1.0061	0.023	44.043	0.000	0.961	1.051
ma.L2	0.9662	0.026	37.434	0.000	0.916	1.017
ar.S.L12	-1.0385	0.724	-1.434	0.152	-2.458	0.381
ar.S.L24	-0.5158	0.405	-1.275	0.202	-1.309	0.277
ar.S.L36	-0.0795	0.243	-0.327	0.744	-0.556	0.397
ma.S.L12	0.5383	0.717	0.750	0.453	-0.868	1.944
sigma2	0.3213	0.025	12.865	0.000	0.272	0.370

Ljung-Box (L1) (Q):	0.02	Jarque-Bera (JB):	7.77
Prob(Q):	0.88	Prob(JB):	0.02
Heteroskedasticity (H):	2.06	Skew:	0.19
Prob(H) (two-sided):	0.00	Kurtosis:	3.75

Vemos que al utilizar un modelo más complejo podemos conseguir un criterio de Akaike superior. Igualmente, la complejidad del modelo afecta al criterio BIC, por lo que se trata de una cuestión personal hacer la elección entre criterios. Como este modelo sigue teniendo problemas de significatividad de coeficientes, vemos p valores de significatividad superiores a 0.05, finalmente opto por llevar a cabo un modelo auto ARIMA, para que este optimice los parámetros correctamente.

El modelo auto ARIMA presenta resultados válidos, puesto que el estadístico Ljung-Box presenta un p valor = 0.87 > 0.05. Aun teniendo coeficientes significativos, presenta un criterio de Akaike superior al de otros modelos vistos (513.963). Los parámetros utilizados para ejecutar la función y sus resultados han sido:

```
modelo = auto_arima(
    y=df['IPC'],
    start_p=0, start_q=0,
    max_p=4, max_q=4,
    start_P=0, start_Q=0,
    max_P=4, max_Q=4,
    m=12,
    seasonal=True,
    test='adf',
    d=None, D=None,
    trace=True,
    error_action='ignore',
    suppress_warnings=True,
    stepwise=True
)
modelo.summary()
```

SARIMAX Results

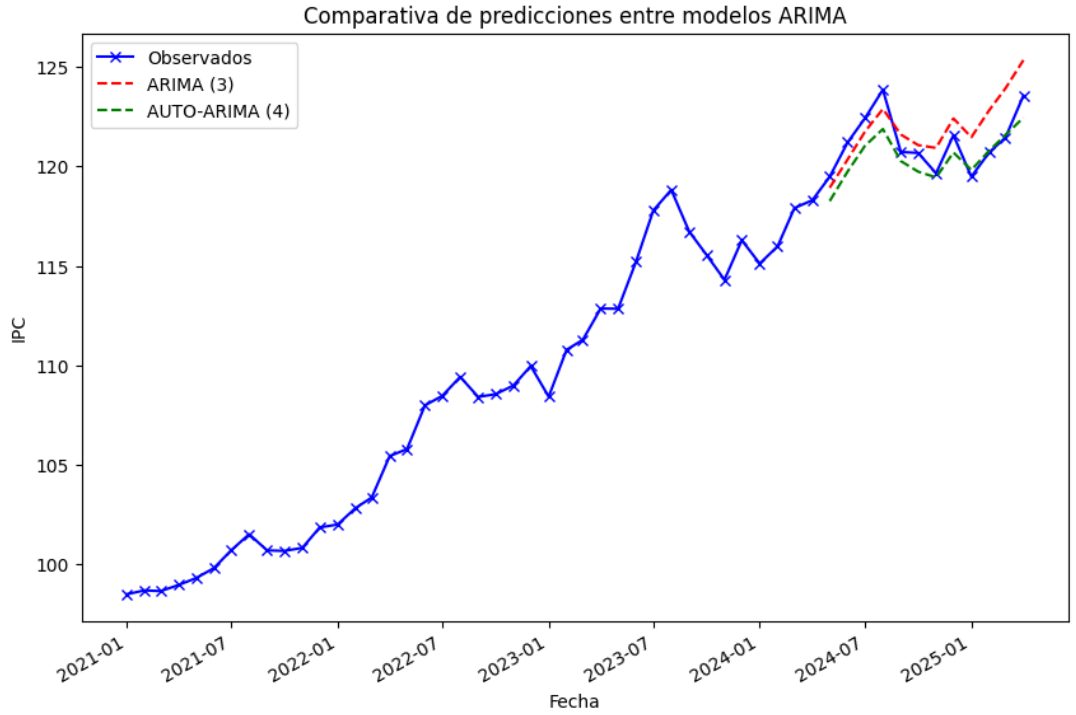
Dep. Variable:			y	No. Observations:		280
Model:	SARIMAX(1, 1, 0)x(1, 0, [1], 12)			Log Likelihood		-251.982
Date:	Thu, 29 May 2025			AIC		513.963
Time:	15:00:38			BIC		532.119
Sample:	01-01-2002			HQIC		521.246
	- 04-01-2025					
Covariance Type:			opg			

	coef	std err	z	P>|z|	[0.025	0.975]
intercept	0.0081	0.009	0.911	0.362	-0.009	0.026
ar.L1	-0.2082	0.054	-3.851	0.000	-0.314	-0.102
ar.S.L12	0.9784	0.013	75.868	0.000	0.953	1.004
ma.S.L12	-0.6653	0.055	-12.018	0.000	-0.774	-0.557
sigma2	0.3323	0.025	13.294	0.000	0.283	0.381

Ljung-Box (L1) (Q):	0.03	Jarque-Bera (JB):	9.81
Prob(Q):	0.87	Prob(JB):	0.01
Heteroskedasticity (H):	1.93	Skew:	0.25
Prob(H) (two-sided):	0.00	Kurtosis:	3.77

El modelo propuesto por auto ARIMA es: **(4)** *ARIMA (1, 1, 0) (1, 0, 1)*$_{12}$.

Ahora vamos a pasar a la validación de modelos, enfrentando a los modelos **(3)** y **(4)** mediante MSE, MEA y RMSE. El proceso de comparación ha sido realizado guardando la última estacionalidad (12 meses) y comparando las estimaciones que ambos modelos hacen de ella.



Las medidas utilizadas para comparar el ajuste de los modelos han sido el error medio absoluto (MAE), el error cuadrático medio (MSE) y la raíz del error cuadrático medio (RMSE).

Como podemos ver, los resultados del cálculo de estos estadísticos es que el modelo auto ARIMA se ajusta mejor, un resultado que también podemos apreciar en el gráfico.

```
ARIMA (3)
MAE: 1.23
MSE: 1.95
RMSE: 1.40

AUTOARIMA (4)
MAE: 0.85
MSE: 1.06
RMSE: 1.03
```

6- Modelo ajustado ganador.

El modelo ganador es ARIMA (1, 1, 0) (1, 0, 1)$_{12}$, cuya expresión algebraica con sus coeficientes es:

$$(1+ 0.2082B)\ (1- 0.9784B^{12})\ (1-B)\ X_t = (1 - 0.6653B^{12})\ Z_t - 0.0081$$

Donde:

Término constante = 0.0081

$\phi 1 = -0.2082$

$\Phi 1 = 0.9784$

$\Theta 1 = -0.6653$

	coef
intercept	0.0081
ar.L1	-0.2082
ar.S.L12	0.9784
ma.S.L12	-0.6653

Y B es el operador de retardos: $\nabla_s X_t = X_t - X_{t-1} = (1 - B^s)\, X_t$

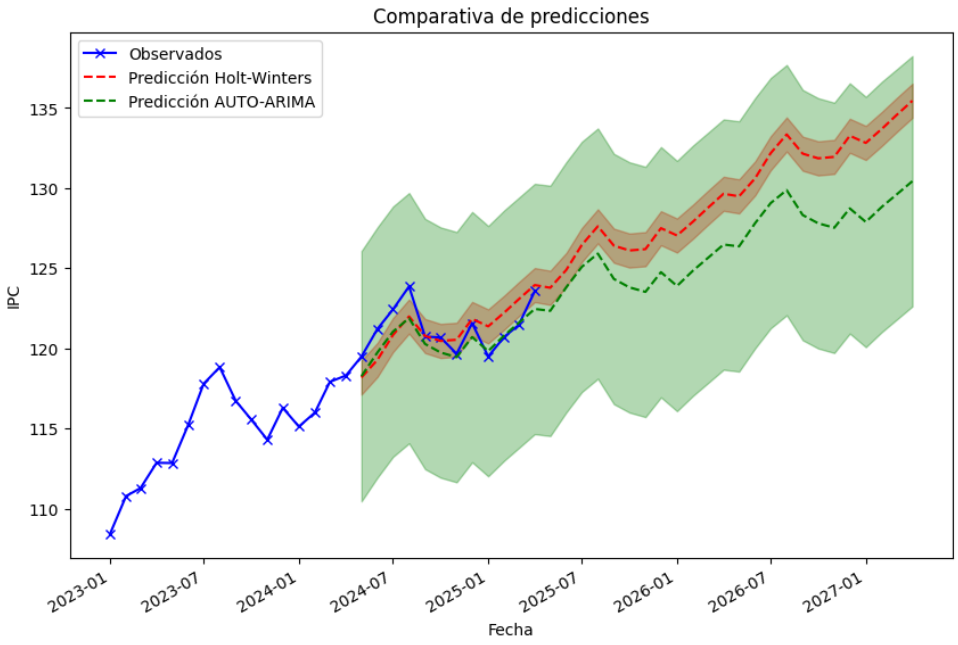
7- Cálculo de predicciones e intervalos de confianza.

Ahora toca enfrentar a los modelos ganadores entre los de suavizado exponencial y los ARIMA: el modelo Holt-Winters mixto (modelizando tendencia de forma multiplicativa y estacionalidad de forma aditiva) y el modelo *ARIMA (1, 1, 0) (1, 0, 1)*$_{12}$. Para ello vamos a predecir hasta 3 años (36 muestras), por ser múltiplo de nuestra unidad estacional (12 meses/ muestras) y a graficarlas con sus intervalos de confianza calculados manualmente.

```
predicciones_statsmodels = modelo_res.get_forecast(steps=61).predicted_mean
predicciones_statsmodels.name = 'predicciones_statsmodels'

pred_hw = modelo_holt_winters.forecast(steps=36)
pred_arima = modelo_res4.get_forecast(steps=36).predicted_mean

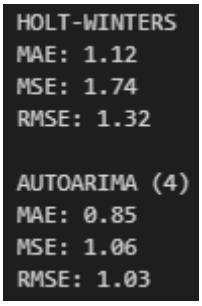
# Intervalos de confianza calculados manualmente
    # Holt-Winter
residualshw = modelo_holt_winters.resid
std_residhw = residualshw.std()
lower_hw = pred_hw - 1.96 * std_residhw #IC al 95%
upper_hw = pred_hw + 1.96 * std_residhw
    # AutoARIMA
residualsaa = modelo_res4.resid
std_residaa = residualsaa.std()
lower_aa = pred_arima - 1.96 * std_residaa #IC al 95%
upper_aa = pred_arima + 1.96 * std_residaa
```



A primera vista el modelo auto ARIMA parece ajustarse mejor a los valores observados durante el último periodo, lo que también nos da una mayor confianza sobre cómo serán las predicciones a futuro. En cuanto al tamaño de las bandas de confianza, los residuos obtenidos de un modelo y de otro no parecen ser comparables puesto que el cálculo interno para cada modelo es distinto. Por ello, si queremos obtener una mejor idea de qué modelo se ajusta mejor, deberíamos comparar las predicciones del último año de los modelos con los valores observados el último año, usando para ello las métricas anteriormente vistas.

8- Comparación de predicciones mediante métricas.

Al comparar las métricas de ambos modelos obtenemos que el modelo ganador es el auto *ARIMA (1, 1, 0) (1, 0, 1)*$_{12}$. No solo podíamos intuirlo a través del gráfico, sino que muestra valores más pequeños de error para las tres medidas observadas (error medio absoluto (MAE), el error cuadrático medio (MSE) y la raíz del error cuadrático medio (RMSE).



Así, damos por finalizado nuestro estudio alrededor de los valores futuros del IPC del sector “Turismo y hostelería” en la Región de Murcia. Hemos visto varias formas de predecir, las hemos puesto a prueba y optimizado hasta dar con nuestro modelo ganador, el que menor error comete. Podemos decir que en ausencia de un shock exógeno que desvíe las tendencias del mercado, los precios seguirán manteniendo una tendencia alcista y mostrando la estacionalidad característica de las ciudades costeras en verano.

Nota: Todo el código queda aclarado en el archivo “PedroPabloVicenteGonzález_Series_Temporales.ipynb” adjunto.